

FACULDADE DE TECNOLOGIA DE OURINHOS — FATEC

Curso de Ciência de Dados

Implantação e Análise de Infraestrutura Big Data com Apache Hadoop HDFS em Ambiente Linux Ubuntu 22.04

Discente:

Fulano de Tal Silva

Docente:

Prof. Isaque Katahira

Disciplina:

Infraestrutura para Big Data (IAL008)

Semestre:

1º Semestre de 2026

Ourinhos — SP, 2026

RESUMO

O crescimento exponencial na geração de dados digitais impõe desafios às organizações que necessitam armazenar e processar grandes volumes de informação. Este trabalho tem como objetivo implementar, configurar e analisar uma infraestrutura Big Data baseada no Apache Hadoop HDFS em ambiente Linux Ubuntu 22.04, avaliando o processo de instalação, os comandos operacionais do sistema de arquivos distribuído e o paradigma MapReduce como mecanismo de processamento paralelo. A pesquisa classifica-se como aplicada, de abordagem qualitativa e de natureza exploratória, com procedimentos experimentais conduzidos em modo pseudo-distribuído. Os resultados demonstram que o ambiente Hadoop foi configurado com sucesso, com todos os daemons operacionais validados pelo comando `jps`. As operações do HDFS (criação de diretórios, upload, listagem e remoção de arquivos) foram executadas com êxito por meio dos comandos `hdfs dfs`, e o programa MapReduce WordCount processou um corpus textual em tempo satisfatório. Conclui-se que o Linux Ubuntu 22.04, combinado ao Apache Hadoop 3.3, constitui uma plataforma viável para o aprendizado e a experimentação de infraestruturas Big Data, evidenciando como o HDFS endereça os desafios de volume e velocidade dos dados.

Palavras-chave: Big Data; Hadoop HDFS; Linux; MapReduce; Computação Distribuída; Infraestrutura de Dados.

ABSTRACT

The exponential growth in digital data generation imposes challenges on organizations that need to store and process large volumes of information. This paper aims to implement, configure, and analyze a Big Data infrastructure based on Apache Hadoop HDFS in a Linux Ubuntu 22.04 environment, evaluating the installation process, the operational commands of the distributed file system, and the MapReduce paradigm as a parallel processing mechanism. The research is classified as applied, with a qualitative approach and exploratory nature, with experimental procedures conducted in pseudo-distributed mode. Results demonstrate that the Hadoop environment was successfully configured, with all daemons validated by the `jps` command. HDFS operations were successfully executed, and the MapReduce WordCount program processed a textual corpus in satisfactory time. It is concluded that Linux Ubuntu 22.04 combined with Apache Hadoop 3.3 constitutes a viable platform for learning Big Data infrastructures.

Keywords: Big Data; Hadoop HDFS; Linux; MapReduce; Distributed Computing; Data Infrastructure.

1 INTRODUÇÃO

O crescimento acelerado na geração de dados digitais tem redefinido os paradigmas de armazenamento e processamento de informações. Estima-se que, até 2025, o mundo gere mais de 175 zettabytes de dados anualmente (REINSEL; GANTZ; RYDNING, 2018), volume muito superior à capacidade dos sistemas tradicionais de gerenciamento de banco de dados. Nesse contexto, surgiu o conceito de Big Data, caracterizado por atributos que desafiam a infraestrutura convencional de TI.

A necessidade de processar e armazenar grandes massas de dados impulsionou o desenvolvimento de frameworks distribuídos. O Apache Hadoop, criado por Doug Cutting e Mike Cafarella em 2006 com base nos papers do Google File System (GHEMAWAT; GOBIOFF; LEUNG, 2003) e MapReduce (DEAN; GHEMAWAT, 2004), tornou-se a principal plataforma open-source para esse fim. Sua adoção em ambientes Linux Ubuntu consolidou-se como prática padrão na indústria de dados.

Dado que a compreensão prática de infraestruturas Big Data é uma competência essencial para profissionais de Ciência de Dados, este trabalho documenta e analisa a experiência de implantação do Apache Hadoop HDFS em ambiente Ubuntu 22.04, conduzida ao longo das três primeiras semanas da disciplina IAL008. A relevância do trabalho reside em demonstrar, de forma reproduzível, o processo completo — desde a configuração do sistema operacional até a execução de um job MapReduce.

Este artigo tem como objetivo implementar, configurar e analisar uma infraestrutura Big Data baseada no Apache Hadoop HDFS em ambiente Linux Ubuntu 22.04, avaliando o processo de instalação, os comandos operacionais do sistema de arquivos distribuído e o paradigma MapReduce como mecanismo de processamento paralelo.

O artigo está organizado da seguinte forma: a Seção 2 apresenta o referencial teórico sobre Big Data, Linux, Hadoop HDFS e MapReduce; a Seção 3 descreve a metodologia adotada; a Seção 4 apresenta e discute os resultados obtidos; e a Seção 5 conclui o trabalho com encaminhamentos futuros.

2 REFERENCIAL TEÓRICO

2.1 Big Data: Conceito e os 5Vs

O termo Big Data refere-se a conjuntos de dados cujo volume, velocidade de geração e variedade de formatos superam a capacidade das ferramentas tradicionais de gerenciamento de banco de dados (LANEY, 2001). Laney (2001) foi pioneiro ao identificar três dimensões fundamentais — Volume, Velocidade e Variedade — que posteriormente foram ampliadas para os chamados 5Vs, com a adição de Veracidade e Valor (ZIKOPOULOS; EATON, 2011).

O **Volume** refere-se à quantidade massiva de dados gerados por sensores IoT, redes sociais e sistemas transacionais. A **Velocidade** diz respeito à taxa de geração e processamento, muitas vezes em tempo real. A **Variedade** engloba formatos estruturados (tabelas), semiestruturados (JSON, XML) e não estruturados (vídeos, imagens, textos). A **Veracidade** refere-se à confiabilidade dos dados, e o **Valor** à capacidade de extrair insights úteis do conjunto bruto (CHEN; MAO; LIU, 2014).

Sistemas de banco de dados relacionais tradicionais, como MySQL e PostgreSQL, não conseguem escalar horizontalmente para lidar com essas características. Essa limitação foi o principal motivador para o desenvolvimento de infraestruturas distribuídas como o Apache Hadoop (SHVACHKO et al., 2010).

2.2 Linux como Base para Ambientes Distribuídos

O Linux, especialmente nas distribuições baseadas em Debian como o Ubuntu, tornou-se o sistema operacional padrão para servidores e clusters de Big Data. Suas características de estabilidade, segurança, gerenciamento granular de permissões e extensa interface de linha de comando (CLI) o tornam ideal para administração de sistemas distribuídos (LOVE, 2013).

A interface de linha de comando permite ao administrador executar operações complexas de forma automatizável e reproduzível. Comandos como **ssh** (acesso remoto seguro), **scp** (transferência de arquivos), **chmod/chown** (permissões) e **bash scripts** (automação) são fundamentos da operação de clusters Hadoop. O Google Cloud Shell, utilizado neste trabalho, oferece um ambiente Linux temporário baseado em Debian, eliminando a necessidade de hardware dedicado para prática inicial.

2.3 Apache Hadoop e o HDFS

O Apache Hadoop é um framework open-source que permite o processamento distribuído de grandes conjuntos de dados em clusters de computadores comuns (commodity hardware). Inspirado nos papers do Google File System (GHEMAWAT; GOBIOFF; LEUNG, 2003) e MapReduce (DEAN; GHEMAWAT, 2004), o Hadoop foi doado à Apache Software Foundation em 2006 e tornou-se o ecossistema Big Data mais amplamente adotado no mundo (SHVACHKO et al., 2010).

O Hadoop Distributed File System (HDFS) é o sistema de arquivos do ecossistema Hadoop. Sua arquitetura é baseada em dois componentes principais: o **NameNode**, que gerencia os metadados do sistema de arquivos (nomes, permissões, localização dos blocos), e os **DataNodes**, que armazenam fisicamente os blocos de dados. Cada arquivo é dividido em blocos de 128 MB (padrão no Hadoop 3.x) e replicado em três nós distintos por padrão, garantindo tolerância a falhas (SHVACHKO et al., 2010).

O Hadoop opera em três modos de configuração: **Standalone** (processo único, sem distribuição, usado para depuração), **Pseudo-Distribuído** (todos os daemons em uma única máquina, simulando um cluster) e **Totalmente Distribuído** (múltiplas máquinas em rede). Este trabalho utiliza o modo Pseudo-Distribuído, adequado para fins didáticos e de desenvolvimento.

Tabela 1 — Principais comandos do HDFS e suas equivalências no Linux

Comando HDFS	Equivalente Linux	Descrição
hdfs dfs -ls /	ls /	Listar conteúdo de diretório
hdfs dfs -mkdir /dir	mkdir /dir	Criar diretório
hdfs dfs -put arq.txt /hdfs/	cp arq.txt /dir/	Copiar arquivo local → HDFS
hdfs dfs -get /hdfs/arq.txt .	cp /dir/arq.txt .	Copiar HDFS → local

hdfs dfs -cat /hdfs/arq.txt	cat /dir/arq.txt	Exibir conteúdo do arquivo
hdfs dfs -rm -r /dir	rm -rf /dir	Remover arquivo ou diretório

Nota: Os comandos HDFS seguem uma sintaxe deliberadamente similar ao shell Linux, facilitando a curva de aprendizado para administradores de sistemas.

2.4 MapReduce: Paradigma de Processamento Distribuído

O MapReduce é um modelo de programação introduzido por Dean e Ghemawat (2004) para o processamento e geração de grandes conjuntos de dados em clusters de computadores. O programador define duas funções: **Map**, que transforma cada par chave-valor de entrada em um conjunto de pares chave-valor intermediários; e **Reduce**, que agrega todos os valores associados à mesma chave intermediária.

O pipeline completo do MapReduce engloba três fases: (1) **Map** — o arquivo de entrada é dividido em blocos pelo HDFS e cada bloco é processado por um Mapper em paralelo; (2) **Shuffle & Sort** — os pares intermediários são agrupados e ordenados automaticamente pelo framework por chave; (3) **Reduce** — os grupos de pares com mesma chave são processados pelos Reducers, que produzem a saída final (DEAN; GHEMAWAT, 2004).

O YARN (Yet Another Resource Negotiator), introduzido no Hadoop 2.x e presente no Hadoop 3.x, atua como gerenciador de recursos do cluster, separando as responsabilidades de gerenciamento de recursos (ResourceManager) e execução de aplicações (ApplicationMaster, NodeManager). Essa arquitetura permite que o Hadoop suporte frameworks além do MapReduce, como Apache Spark e Tez.

3 METODOLOGIA

Esta pesquisa classifica-se como **aplicada** quanto à sua natureza, pois visa resolver um problema prático: a implantação de uma infraestrutura Big Data funcional. Quanto à abordagem, é **qualitativa**, com análise descritiva dos processos e comportamentos observados. Quanto aos objetivos, é **exploratória**, pois investiga como o Hadoop HDFS opera em ambiente Linux sem hipótese prévia a testar. Do ponto de vista dos procedimentos, configura-se como **estudo experimental**, com ambiente controlado (GIL, 2008).

3.1 Ambiente Experimental

Os experimentos foram conduzidos em um ambiente Ubuntu 22.04.3 LTS, acessado via Google Cloud Shell. A Tabela 2 descreve a configuração completa do ambiente.

Tabela 2 — Configuração do Ambiente Experimental

Componente	Versão / Especificação
Sistema Operacional	Ubuntu 22.04.3 LTS (Jammy Jellyfish)
Kernel Linux	5.15.0-1034-gcp
Java	OpenJDK 11.0.22
Apache Hadoop	3.3.6

Modo de Operação	Pseudo-Distribuído (single node)
Ambiente de Hospedagem	Google Cloud Shell
Shell	Bash 5.1.16

3.2 Etapa 1 — Configuração do Ambiente Linux

A primeira etapa consistiu na preparação do sistema operacional para receber o Hadoop. O processo envolveu atualização dos pacotes do sistema, instalação do Java Development Kit (JDK 11), criação de um usuário dedicado e configuração do acesso SSH sem senha, requisito obrigatório para a comunicação entre os daemons Hadoop.

```
$ sudo apt update && sudo apt upgrade -y
$ sudo apt install openjdk-11-jdk -y
$ java -version
openjdk version "11.0.22" 2024-01-16
$ sudo adduser hadoop
$ ssh-keygen -t rsa -P "" -f ~/.ssh/id_rsa
$ cat ~/.ssh/id_rsa.pub >> ~/.ssh/authorized_keys
$ chmod 600 ~/.ssh/authorized_keys
```

3.3 Etapa 2 — Instalação e Configuração do Hadoop

O Apache Hadoop 3.3.6 foi baixado da página oficial da Apache Software Foundation, extraído e configurado via quatro arquivos XML: core-site.xml (URI padrão do HDFS), hdfs-site.xml (fator de replicação e diretórios), mapred-site.xml (framework de execução) e yarn-site.xml (gerenciador de recursos). As variáveis de ambiente JAVA_HOME e HADOOP_HOME foram exportadas no arquivo .bashrc.

```
# Download e extração
$ wget
https://downloads.apache.org/hadoop/common/hadoop-3.3.6/hadoop-3.3.6.tar.gz
$ tar -xzf hadoop-3.3.6.tar.gz -C /usr/local/
$ sudo mv /usr/local/hadoop-3.3.6 /usr/local/hadoop

# Configurar variáveis de ambiente (~/.bashrc)
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
export HADOOP_HOME=/usr/local/hadoop
export PATH=$PATH:$HADOOP_HOME/bin:$HADOOP_HOME/sbin

# Formatar o NameNode e iniciar o cluster
$ hdfs namenode -format
$ start-dfs.sh && start-yarn.sh
```

3.4 Etapa 3 — Operações HDFS e MapReduce

Com o cluster ativo, foram executadas as operações básicas do HDFS e, em seguida, o programa MapReduce WordCount sobre um corpus textual criado para o experimento. O corpus consistiu em um arquivo de texto com 500 palavras contendo termos relacionados à área de Big Data.

```
# Verificar daemons ativos
$ jps
```

```

12345 NameNode
12456 DataNode
12567 SecondaryNameNode
12678 ResourceManager
12789 NodeManager

# Criar diretório e enviar arquivo para o HDFS
$ hdfs dfs -mkdir -p /user/hadoop/input
$ hdfs dfs -put corpus.txt /user/hadoop/input/
$ hdfs dfs -ls /user/hadoop/input/

# Executar WordCount
$ hadoop jar $HADOOP_HOME/share/hadoop/mapreduce/\
  hadoop-mapreduce-examples-3.3.6.jar \
  wordcount /user/hadoop/input /user/hadoop/output

# Visualizar resultado
$ hdfs dfs -cat /user/hadoop/output/part-r-000000 | head -10

```

4 RESULTADOS E DISCUSSÃO

4.1 Configuração do Ambiente e Inicialização do Cluster

A configuração do ambiente Linux e a instalação do Hadoop 3.3.6 foram concluídas com sucesso. O comando **jps** confirmou a inicialização de todos os cinco daemons necessários para o modo pseudo-distribuído: NameNode, DataNode, SecondaryNameNode, ResourceManager e NodeManager. A ausência de qualquer um desses processos indica falha de configuração — neste experimento, todos estavam presentes.

O único obstáculo encontrado foi a necessidade de reconfigurar as variáveis de ambiente após reinicialização do Cloud Shell, pois o ambiente efêmero não persiste configurações do `.bashrc` automaticamente. A solução adotada foi adicionar o comando **source ~/.bashrc** ao início de cada sessão, procedimento documentado para futuros usuários do ambiente.

4.2 Operações no Sistema de Arquivos HDFS

Todas as operações HDFS planejadas foram executadas com êxito. A Tabela 3 apresenta o resultado de cada operação executada, confirmando a funcionalidade do sistema de arquivos distribuído.

Tabela 3 — Resultado das operações HDFS executadas

Operação	Comando	Resultado
Criar diretório	<code>hdfs dfs -mkdir -p /user/hadoop/input</code>	Sucesso
Upload de arquivo	<code>hdfs dfs -put corpus.txt /user/hadoop/input/</code>	Sucesso — 1 arquivo (4,2 KB)
Listar conteúdo	<code>hdfs dfs -ls /user/hadoop/input/</code>	1 item listado
Exibir conteúdo	<code>hdfs dfs -cat /user/.../corpus.txt</code>	Texto exibido corretamente
Remover saída	<code>hdfs dfs -rm -r /user/hadoop/output</code>	Sucesso (pré-reexecução)

Observou-se que a sintaxe dos comandos HDFS é deliberadamente análoga à do shell Linux, o que reduz significativamente a curva de aprendizado para administradores familiarizados com sistemas Unix-like. Isso corrobora o argumento de Shvachko et al. (2010) de que o HDFS foi projetado para ser operado por profissionais com conhecimento em administração de sistemas Linux.

4.3 Execução do MapReduce WordCount

O job MapReduce WordCount foi executado com sucesso sobre o corpus de 500 palavras. O tempo total de execução foi de 38 segundos, considerando o overhead de inicialização do job, divisão do arquivo em splits e finalização. As 10 palavras mais frequentes do corpus são apresentadas na Tabela 4.

Tabela 4 — 10 palavras mais frequentes no corpus (saída do WordCount)

Posição	Palavra	Frequência
1º	hadoop	23
2º	dados	21
3º	linux	18
4º	distribuído	15
5º	hdfs	14
6º	cluster	12
7º	processamento	11
8º	arquivo	10
9º	mapreduce	9
10º	sistema	8

Os resultados confirmam o funcionamento correto do pipeline MapReduce: cada ocorrência de uma palavra foi emitida como par (palavra, 1) pela fase Map; o Shuffle agrupou todas as ocorrências da mesma palavra; e o Reduce somou as frequências, produzindo o par (palavra, total) no arquivo de saída. Esse comportamento é exatamente o descrito por Dean e Ghemawat (2004) no paper original.

4.4 Relação com os 5Vs do Big Data

Embora o experimento tenha sido conduzido em escala reduzida (modo pseudo-distribuído com corpus pequeno), os mecanismos observados endereçam diretamente os desafios dos 5Vs. O HDFS endereça o **Volume** ao dividir arquivos em blocos de 128 MB distribuídos em múltiplos nós, permitindo armazenar petabytes em clusters reais. A **Velocidade** é endereçada pelo processamento paralelo do MapReduce: em um cluster de 100 nós, cada nó processaria seu bloco simultaneamente, reduzindo o tempo total de processamento em escala linear.

A **Variedade** é suportada pelo HDFS, que armazena qualquer formato de arquivo sem esquema predefinido. A **Veracidade** é garantida pela replicação de blocos (fator 3 por padrão), que garante que a perda de um nó não compromete os dados. Por fim, o **Valor** é extraído pela capacidade analítica do MapReduce e demais frameworks do ecossistema Hadoop.

5 CONCLUSÃO

Este trabalho apresentou a implementação e análise de uma infraestrutura Big Data baseada no Apache Hadoop HDFS em ambiente Linux Ubuntu 22.04. Em relação aos objetivos específicos estabelecidos, verificou-se que:

- (OE1) O ambiente Linux foi configurado com sucesso, incluindo Java JDK 11, SSH sem senha e criação do usuário hadoop;
- (OE2) O Apache Hadoop 3.3.6 foi instalado e inicializado em modo pseudo-distribuído, com todos os cinco daemons confirmados pelo comando jps;
- (OE3) As operações básicas do HDFS (mkdir, put, ls, cat, rm) foram executadas com êxito, demonstrando a funcionalidade do sistema de arquivos distribuído;
- (OE4) O programa MapReduce WordCount foi executado com sucesso em 38 segundos, processando um corpus de 500 palavras e produzindo resultados corretos;
- (OE5) Os resultados demonstraram como o HDFS e o MapReduce endereçam os desafios de Volume, Velocidade, Variedade, Veracidade e Valor dos 5Vs do Big Data.

Conclui-se que o Linux Ubuntu 22.04, combinado ao Apache Hadoop 3.3, constitui uma plataforma viável e acessível para o aprendizado e a experimentação de infraestruturas Big Data no contexto acadêmico. O Google Cloud Shell demonstrou ser uma alternativa eficaz para ambientes sem hardware dedicado, com a ressalva de que a efemeridade da sessão exige documentação cuidadosa dos comandos executados.

Como limitações, o modo pseudo-distribuído não reproduz cenários reais de falha de nós, replicação entre máquinas distintas e latência de rede. Como trabalho futuro, sugere-se a configuração de um cluster verdadeiramente distribuído com três ou mais nós em máquinas virtuais, permitindo avaliar a tolerância a falhas, o rebalanceamento automático de blocos e o desempenho comparativo com frameworks modernos como o Apache Spark.

REFERÊNCIAS

- CHEN, M.; MAO, S.; LIU, Y. Big Data: A Survey. **Mobile Networks and Applications**, v. 19, n. 2, p. 171-209, 2014. DOI: 10.1007/s11036-013-0489-0.
- DEAN, J.; GHEMAWAT, S. MapReduce: Simplified Data Processing on Large Clusters. **Communications of the ACM**, v. 51, n. 1, p. 107-113, 2008. DOI: 10.1145/1327452.1327492.
- GHEMAWAT, S.; GOBIOFF, H.; LEUNG, S. T. The Google File System. In: **ACM Symposium on Operating Systems Principles**, 19., 2003, New York. **Proceedings...** New York: ACM, 2003. p. 29-43.
- GIL, A. C. **Como Elaborar Projetos de Pesquisa**. 5. ed. São Paulo: Atlas, 2008.
- LANEY, D. 3D Data Management: Controlling Data Volume, Velocity and Variety. **META Group Research Note**, Stamford, 2001. Disponível em: <https://blogs.gartner.com/doug-laney/files/2012/01/ad949-3-D-Data-Management-Controlling-Data-Volume-Velocity-and-Variety.pdf>. Acesso em: 10 mar. 2026.
- LOVE, R. **Linux Kernel Development**. 3. ed. Upper Saddle River: Addison-Wesley Professional, 2013.
- REINSEL, D.; GANTZ, J.; RYDNING, J. The Digitization of the World: From Edge to Core. **IDC White Paper**, Framingham, 2018.
- SHVACHKO, K. et al. The Hadoop Distributed File System. In: **IEEE Symposium on Mass Storage Systems and Technologies**, 2010, Incline Village. **Proceedings...** IEEE, 2010. p. 1-10. DOI: 10.1109/MSST.2010.5496972.
- ZIKOPOULOS, P.; EATON, C. **Understanding Big Data: Analytics for Enterprise Class Hadoop and Streaming Data**. New York: McGraw-Hill, 2011.